

Cristhian SANCHEZ
Ingeniero de Machine Learning e IA

in linkedin.com/in/cristhian-wiki
github.com/HiroForYou
www.cristhianwiki.com
+51 924130271
christiansanchezsaune@gmail.com
La Victoria, Lima, Perú
8 de junio de 1998 (28 años)



Ingeniero de IA especializado en IA Agéntica y sistemas basados en LLMs, con más de 3 años diseñando y desplegando arquitecturas multi-agente de nivel productivo (tool calling, handoffs, orquestación y RAG), sobre una base más amplia de más de 6 años de experiencia en Machine Learning en analítica predictiva, Computer Vision y NLP.

Lidero la arquitectura de soluciones de IA end-to-end desde la experimentación hasta la producción, combinando rigor matemático, MLOps e ingeniería cloud-native con liderazgo técnico hands-on para generar impacto de negocio medible.

HABILIDADES

Table with 2 columns: Skill Category and Skills. Categories include IA & IA Generativa, Frameworks, Computer Vision, Despliegue de Modelos, MLOps, Stack de Datos, Plataformas de Datos, Cloud, and Sistemas.

EXPERIENCIA PROFESIONAL

Table with 3 columns: Date, Job Title, and Description. Includes roles like Ingeniero de Machine Learning Senior at SEIDOR ANALYTICS and various client projects at Koandina, Bodegas La Negrita, Arca Continental, and Industrias San Miguel.

Ciente : Innova Sports - Industria Retail

- Desarrollé soluciones de pronóstico de demanda para productos retail basadas en escenarios de campañas de descuento planificadas.
- Usé notebooks de Amazon SageMaker para análisis exploratorio de datos, training jobs de SageMaker para el desarrollo de modelos, y SageMaker Pipelines para automatizar el entrenamiento e inferencia de modelos.

IA Agéntica RAG NVIDIA DGX Snowflake ML AWS (Kinesis, Athena, SageMaker, CloudFormation) Azure Python MLOps

Noviembre 2024
Junio 2025

Tech Lead, Sokso, Lima, PE

Híbrido, Completo

- Lideré el diseño arquitectónico de la plataforma SMART 3.0, supervisando y asignando tareas a los equipos de desarrollo backend y frontend, y estableciendo estándares técnicos de implementación.
- Encabecé el proyecto estratégico de migración del sistema ERP de SAP a NetSuite, coordinando la transferencia de datos críticos, rediseñando procesos de negocio y asegurando la continuidad operativa durante la transición.
- Gestioné la infraestructura AWS de la empresa, implementando automatizaciones de despliegue en instancias EC2, configurando pipelines de CI/CD y optimizando costos y rendimiento de los servicios cloud.

AWS (EC2, ECS, S3) CI/CD DevOps NetSuite SAP ERP Nest.js Next.js Technical Leadership

Noviembre 2023
Noviembre 2024

Desarrollador Full Stack, Sokso, Lima, PE

Híbrido, Completo

- Lideré el diseño e implementación de mejoras avanzadas al frontend (Vue.js) de la plataforma SMART 2.0, optimizando la experiencia de usuario en módulos críticos como el sistema de contacto con clientes, y apliqué mejoras en prácticas de ciberseguridad, estableciendo estándares de desarrollo seguro tanto para frontend como backend (.NET).
- Contribuí al desarrollo inicial de la versión 3.0 de la plataforma core SMART, usando Nest.js en el backend, Next.js en el frontend, y configurando un pipeline DevOps robusto en AWS (ECS, S3, CI/CD), logrando una infraestructura ágil, escalable y de alta disponibilidad.
- Implementé múltiples automatizaciones en Python para agilizar tareas en las áreas comercial y de diseño, incluyendo scripts de procesamiento de datos, generación de reportes personalizados y flujos de trabajo automatizados que mejoraron la eficiencia y redujeron el tiempo de trabajo manual en ambas áreas.
- Desarrollé proyectos piloto de machine learning: un modelo de pronóstico de ventas de los próximos meses usando técnicas de series de tiempo, y un modelo de clasificación para predecir el churn de clientes (Python, PyTorch, GCP), lo que mejoró la precisión en la gestión de inventario y permitió anticipar patrones de abandono, optimizando la retención de clientes.

Vue.js .NET SQL Server Machine Learning Python GCP AWS (EC2, ECS, S3) CI/CD Next.js DevOps

Noviembre 2023
Marzo 2025

Desarrollador Full Stack especializado en IA, ARKRISK, New York, US

Remoto, Parcial

- Lideré la arquitectura y entrega de un **sistema multi-agente en producción** (agente de OCR → agente de Validación, handoff secuencial, orquestado con **LangGraph**) para el procesamiento automatizado de pólizas de seguro, combinando modelos personalizados en PyTorch, una **VectorDB** para contexto de referencia, y APIs de tools personalizadas en Node.js para validar los datos extraídos contra reglas de negocio.
- Impulsé la evolución del sistema hacia **AWS Bedrock** y **Guardrails**, e implementé **observabilidad** (logging/tracing a nivel de contenedor más métricas de CloudWatch) y un ciclo de **evaluación** a partir de casos de fallo reportados por el cliente, para monitorear y mejorar la confiabilidad de los agentes en producción.
- Construí un segundo sistema conversacional basado en **RAG** con memoria y function tools (FastAPI, LangGraph, Ollama), integrando LLMs locales (DeepSeek, Llama3, Phi4) por privacidad de datos, además de integraciones con **OpenAI Assistants v2** para chatbots de QA.
- Entregué el producto alrededor del sistema: un frontend en Next.js consumiendo respuestas del LLM mediante **streaming** en tiempo real, integraciones con AWS (EC2, DynamoDB, S3), y automatizaciones en Python para flujos de trabajo internos.

Sistemas Multi-Agente LangGraph VectorDB AWS (EC2, DynamoDB, Bedrock, CloudWatch) Guardrails RAGs FastAPI Ollama DeepSeek OCR Next.js LLMs OpenAI

Mayo 2023 Octubre 2023	Ingeniero de Machine Learning, IMPACTO AI, Lima, PE <i>Remoto, Completo</i> > Lideré el desarrollo de bots de WhatsApp potenciados por LLMs (Chat-GPT) combinando RAG y function tools para automatizar flujos de negocio reales (agendamiento de citas, recordatorios y consultas de estado de pagos), una primera experiencia práctica con RAG y function calling en LLMs. > Extendí la línea de chatbots a Messenger e Instagram, e incorporé procesamiento de documentos con OCR basado en OpenCV avanzado. Function Calling RAG Chat-GPT OpenCV
Enero 2022 Diciembre 2022	Desarrollador Full Stack, AMAUTEACH PROJECT, Lima, PE <i>Remoto, Completo</i> > Desarrollé AmauTeach Exam, una plataforma de exámenes en línea enfocada en la prevención de plagio usando técnicas avanzadas de procesamiento de datos y machine learning. Usé tecnologías como Vue, Flask, FastAPI y Node. > Realicé integraciones con servicios de AWS, usando Cognito para autenticación de usuarios, S3 para almacenamiento de contenido multimedia, y funciones Lambda para optimizar microservicios relacionados con el procesamiento de datos. Vue Node.js Security AWS Big Data
Julio 2021 Diciembre 2021	Desarrollador Full Stack, CHAZKI, Lima, PE <i>Remoto, Completo</i> > Contribuí al desarrollo de funcionalidades críticas en la plataforma logística de Chazki, trabajando en servicios web y la aplicación móvil, usando tecnologías como Vue, React Native, Node y Google Cloud. > Contribuí al backend desarrollado con Spring Boot para el cálculo de rutas mínimas de entrega para los conductores, implementando algoritmos de optimización con Java, usando Spring Data JPA y REST APIs, logrando mejores tiempos de entrega y costos operativos optimizados. > Implementé y mantuve brokers de mensajería como Kafka para asegurar una transmisión de datos eficiente y en tiempo real en un entorno Big Data. Logistics Vue React Native Node Java Spring Boot Spring Data JPA REST APIs Databases Big Data Kafka
Octubre 2020 Julio 2021	Desarrollador Full Stack y Científico de Datos, MDP CONSULTING, Lima, PE <i>Remoto, Completo</i> > Gestioné pipelines de datos en IBM Cloud para mejorar la gestión de cobranza en instituciones bancarias, asegurando la seguridad de los datos en entornos Big Data. > Apliqué clustering y otras técnicas de análisis de Machine Learning sobre los datos de llamadas de cobranza para identificar patrones y estadísticas de comportamiento, usando librerías como pandas, scikit-learn y Jupyter Notebooks. > Realicé pruebas exhaustivas de seguridad, incluyendo pruebas de inyección SQL con herramientas como SQLInjectMe, Sqliv y Sqlmap, como medida preventiva ante posibles ataques. Data Security Clustering Flask Automation Big Data
Julio 2020 Octubre 2020	Ingeniero de Computer Vision Freelance, LUZ DEL SUR, Lima, PE <i>Remoto, Freelance</i> > Construí un modelo de Deep Learning basado en redes CNN para el reconocimiento automático de dígitos y letras en medidores eléctricos para esta empresa peruana de servicio eléctrico, como parte de un flujo de automatización de lectura de medidores basado en OCR que redujo el trabajo manual de digitación. Computer Vision CNNs Deep Learning OCR PyTorch

IDIOMAS

- > Inglés (B1)
- > Japonés (intermedio)

FORTALEZAS

- > Autodidacta
- > Responsable
- > Autónomo
- > Líder

EDUCACIÓN

- > Bachiller en Ciencias de la Computación - Universidad Nacional de Ingeniería (UNI), Perú (2018 - 2023)

LOGROS

- > Beca 18 - PRONABEC (beca para estudiantes con alto rendimiento académico)
- > Top 5% (2018 - 2023) - Facultad de Ciencias - UNI

CERTIFICADOS

- > Deep Learning Specialization - Coursera
- > AI in Medicine - Coursera
- > Advanced MLOps Bootcamp | Machine Learning Operation Hands-on - Udemy
- > AWS Certified Machine Learning Specialty 2024 - Hands On! - Udemy
- > Oracle AI Vector Search Professional

PRESENTACIONES

- | | | |
|----------|---|--|
| Sep 2022 | Introducción a Computer Vision usando Deep Learning, UNI - IEEE CIS |  Post |
| Oct 2020 | Introducción al Deep Learning, UNI - FC |  Post |
| Ago 2020 | Introducción a la IA, UNI - FC |  Post |

PROYECTOS

UNI-MEDIC

2020 - 2021

 github.com/uniMedic

Se desarrolló un chatbot médico usando Deep Learning para diagnósticos en tiempo real. La aplicación móvil se creó con React Native, el backend con Express.js para gestionar registros e historiales médicos, y Flask para consumir modelos de Inteligencia Artificial. Desplegado en la nube de AWS usando Amplify, Cognito y DynamoDB.

[React Native](#) [Express.js](#) [Flask](#) [AWS](#) [Pytorch](#)

RASPI-BLOODVIEW

2020 - 2021

 github.com/Enigma-A-I/RasPi-BloodView

Sistema de detección de células sanguíneas desplegado en una Raspberry Pi 4 usando PyTorch. El modelo de red neuronal convolucional permite un reconocimiento rápido y económico de 3 tipos de células sanguíneas. Cuenta con una interfaz personalizada en HTML/CSS renderizada con Flask y un sistema de gestión de archivos para almacenamiento seguro en el servidor.

[PyTorch](#) [Raspberry Pi](#)

REFERENCIAS

Arom Bautista

Scrum Master, SOKSO

@ arombautista@gmail.com

☎ +51 959 737 755

Diego Natividad

Desarrollador Backend, SOKSO

@ dnatividadlecca@gmail.com

☎ +51 931 839 397

Romeo Maita

Jefe de IT, SOKSO

@ rmaita26@gmail.com

☎ +51 931 633 846

Hugo Gallardo

Ingeniero de Datos Senior, KOANDINA

@ hugo.gif@gmail.com

☎ +56 9 5008 6422

Angel Mayta

Líder de Ciencia de Datos, ISM

@ amayta@unsa.edu.pe

☎ +51 962 809 009

Diego Sánchez

Gerente de Producto, IMPACTO AI

@ dsm.innovation@gmail.com

☎ +51 992 794 636